



CuentaVoz
Tu voz cuenta

Guía técnica

Cómo está construido CuentaVoz
por dentro: arquitectura, agente de
voz, modelo de datos, pruebas y
despliegue.

VERSIÓN **5.0**

AGOSTO DE 2026

DIRIGIDO AL **EQUIPO TÉCNICO**

QUE MANTIENE LA PLATAFORMA



PREPARADO POR STOCKXPERS

Contenido

Las secciones 1 a 3 son el panorama y el arranque. De la 4 a la 11 va el sistema por dentro, pieza por pieza. Las últimas cuatro son la operación: pruebas, despliegue, decisiones y qué hacer cuando algo falla.

1	Qué es CuentaVoz	PANORAMA
2	La arquitectura en una página	PANORAMA
3	Poner el proyecto a andar	ARRANQUE
4	Identidad y permisos	POR DENTRO
5	El agente de voz	POR DENTRO
6	El modelo de datos	POR DENTRO
7	La API	POR DENTRO
8	El frontend	POR DENTRO
9	Trabajar sin conexión	POR DENTRO
10	Reportes y archivos	POR DENTRO
11	Trazabilidad y auditoría	POR DENTRO
12	Pruebas	OPERACIÓN
13	Despliegue	OPERACIÓN
14	Decisiones de diseño	OPERACIÓN
15	Cuando algo falla	OPERACIÓN

1 Qué es CuentaVoz

El problema que resuelve, y por qué se resuelve hablando.

CuentaVoz reemplaza la planilla de papel del conteo de inventario en las bodegas de alimentos y bebidas. En vez de anotar en una hoja y después transcribir a un archivo, la persona **dicta lo que ve** — «arroz, veinte kilos» — y la plataforma lo entiende, lo confirma en voz alta y lo guarda con el código oficial del catálogo.

Eso quita los dos puntos donde se pierde la información: la letra en la planilla y la transcripción posterior. Y como quien cuenta tiene las manos ocupadas, hablar es la única interfaz que no lo obliga a soltar el producto.

LA REGLA QUE GOBIERNA TODO EL SISTEMA

CuentaVoz **siempre confirma antes de guardar, y nunca sobrescribe**. Cada dato que entra pasa por una confirmación explícita de la persona, y cuando se corrige una cantidad el valor anterior no se borra: queda en el registro de trazabilidad. Si alguna vez una función nueva rompe esa regla, es la función la que está mal.

Los dos perfiles

PERFIL	QUÉ HACE	QUÉ VE
Auxiliar de inventarios auxiliar	Cuenta las bodegas que le asignaron, pide insumos al almacén y legaliza el servicio del turno.	9 opciones de menú.
Administrador de bodega auditor	Todo lo anterior, más auditar, aprobar lo que se creó durante el conteo, sacar los reportes y administrar la configuración.	13 opciones de menú.

El perfil vive en `usuario.perfil` y vale `auxiliar` o `auditor`. En el código el administrador se llama siempre `auditor`; «Administrador de bodega» es solo la etiqueta que se le muestra a la gente.

2 La arquitectura en una página

Cuatro piezas y tres servicios externos. Nada más.

PIEZA	TECNOLOGÍA	DE QUÉ RESPONDE
Frontend frontend/	React 18 + Vite, PWA	Las 14 vistas, el reconocimiento de voz del navegador, la cola sin conexión y el diálogo con Cognito.
Backend backend/	FastAPI + Uvicorn	90 endpoints, las reglas del negocio, la conversación con el agente y la generación de archivos.
Base de datos	SQLAlchemy 2 sobre SQLite (local) o PostgreSQL (producción)	18 tablas. El mismo código sirve para las dos: solo cambia DB_URL .
Servicios backend/servicios/	Python puro	Intérprete local, recetas, conciliación, analítica, validación y archivos. Sin FastAPI adentro, por eso se pueden probar solos.

Los tres servicios externos

SERVICIO	PARA QUÉ	SI NO ESTÁ
AWS Cognito	Identidad: registro, ingreso, cambio de clave, verificación en dos pasos.	No se puede entrar. Es la única dependencia dura.
Google Gemini	Entender lo que la persona dice, en lenguaje libre.	Entra el intérprete local: entiende menos variantes, pero el flujo completo sigue funcionando.
Brevo (correo)	Avisar por correo de un mensaje al administrador.	El mensaje igual queda en la bandeja; se ofrece abrir el correo del propio dispositivo.

EL PATRÓN QUE SE REPITE: DEGRADARSE SIN ROMPERSE

Ninguna función se cae por completo cuando falla algo de afuera. Sin Gemini hay intérprete local; sin internet hay cola local que se sincroniza sola; sin servicio de correo el mensaje queda igual registrado. Es la diferencia entre una demo y algo que se puede usar en una bodega con señal irregular.

3 Poner el proyecto a andar

De un clon a la aplicación abierta en el navegador.

Qué necesita instalado

HERRAMIENTA	VERSIÓN	PARA QUÉ
Python	3.12 o superior	El backend.
Node.js	18 o superior	El frontend y las pruebas.
Git	cualquiera reciente	Traer el proyecto.

Backend

- 1 Cree el entorno virtual**
`cd backend` y luego `python -m venv .venv`.
- 2 Actívelo**
en Windows, `.venv\Scripts\activate`; en Linux o macOS, `source .venv/bin/activate`.
- 3 Instale las dependencias**
`pip install -r requirements.txt`.
- 4 Copie el archivo de configuración**
`.env.ejemplo` a `.env` y llene las llaves (ver el cuadro siguiente).
- 5 Arranque**
`uvicorn main:app --reload`. Queda en `http://127.0.0.1:8000`.

Frontend

- 1 Instale**
`cd frontend` y `npm install`.
- 2 Arranque**
`npm run dev`. Queda en `http://localhost:5173`.

El frontend apunta por defecto a `http://127.0.0.1:8000`. Para apuntarlo a otro backend, defina `VITE_API_URL` antes de arrancar.

Las variables de entorno

VARIABLE	OBLIGATORIA	QUÉ CONTROLA
COGNITO_REGION COGNITO_USER_POOL_ID COGNITO_APP_CLIENT_ID	Sí	Identifican el User Pool. No son secretos: viajan dentro del JavaScript que descarga cualquiera.
AWS_ACCESS_KEY_ID AWS_SECRET_ACCESS_KEY	Sí	Credenciales de una cuenta IAM propia del backend, con permiso solo sobre ese User Pool. Nunca la cuenta que creó el pool.
DB_URL	No	Por defecto <code>sqlite:///cuentavoz.db</code> . En producción, la cadena de PostgreSQL.
GOOGLE_API_KEY	No	Activa Gemini. Sin ella entra el intérprete local.
UMBRAL_ANOMALIA	No	Qué tan grande debe ser una diferencia para disparar una alerta. Por defecto <code>0.5</code> (50 %).
ORIGEN_PERMITIDO	No	Orígenes extra para CORS, separados por coma. Los puertos 5173 y 4173 ya vienen permitidos.
SENTRY_DSN	No	Monitoreo de errores. Vacía, no se inicializa nada.

CUENTAS DE DEMOSTRACIÓN

Con la variable de siembra activa y la tabla de usuarios vacía, el backend crea `luis` , `diana` , `stephanie` y `valentina` con la clave `StockXperts1` . No la active en un despliegue con datos reales: `diana` tiene perfil de administrador.

4 Identidad y permisos

Quién es quién, y qué puede tocar cada quien.

La clave nunca pasa por el backend

El registro, el ingreso, el cambio de clave y la verificación en dos pasos los maneja **AWS Cognito directamente**: el frontend habla con el SDK de Cognito y la clave nunca llega a este servidor. El backend no puede filtrar una clave que nunca ve.

Lo único que hace **backend/seguridad.py** es comprobar que el *access token* que llega en la cabecera **Authorization** de verdad lo firmó nuestro User Pool: firma RS256 contra las llaves públicas que Cognito publica, emisor, audiencia, y que sea un access token y no un id token.

Los dos niveles de permiso

NIVEL	CÓMO SE APLICA	QUÉ PROTEGE
Por perfil	<code>Depends(requiere_perfil("auditor"))</code> en el endpoint.	Auditoría, Panel, Reportes y Ajustes.
Por bodega	La tabla <code>asignacion_bodega</code> .	Un auxiliar solo puede contar las zonas que le asignaron.

EL PERMISO POR BODEGA SE APLICA EN CUATRO SITIOS, NO EN UNO

Listar bodegas, abrir una bodega, ver su detalle y la **búsqueda por voz**. Ocultar la opción en el menú no es seguridad: si la restricción no está también en el endpoint, basta con pedir la URL a mano. Por eso el agente de voz también la respeta — es la puerta que más fácil se olvida.

Cerrar sesión de verdad

«Cerrar sesión» no se limita a borrar el token de este navegador: llama a `/api/usuarios/yo/cerrar-todas`, que revoca la sesión en Cognito. Sin eso, el access token seguía siendo válido hasta vencer solo — hasta una hora. En una tableta que se pasan entre turnos, eso es una cuenta abierta para el siguiente.

5 El agente de voz

De «arroz, veinte kilos» a una fila en la base de datos.

El recorrido de una frase

- 1 El navegador escucha**
con la API `SpeechRecognition`, en español de Colombia. El audio no sale del dispositivo: lo que viaja es el texto.
- 2 El texto llega al backend**
por `POST /api/agente/turno`, junto con la sesión de conteo y el contexto de lo que quedó pendiente de confirmar.
- 3 El agente interpreta**
Gemini recibe la frase, el contexto y las reglas, y devuelve una intención con sus datos. Sin llave de Gemini, ese trabajo lo hace el intérprete local.
- 4 Se resuelve el artículo**
el nombre dictado se empareja contra el catálogo con `rapidfuzz` y la tabla de alias. Si hay varias candidatas, se devuelven como opciones para que la persona elija.
- 5 Se valida**
si la cantidad se sale del umbral, o la unidad no coincide, o el número es imposible, se genera una alerta
antes
de guardar.
- 6 Se confirma y se guarda**
la plataforma repite lo que entendió y espera un «confirmo». Solo entonces se escribe la fila y se registra la traza.

Por qué hay dos intérpretes

`backend/servicios/interprete.py` es un intérprete escrito a mano: reconoce números en palabras («veinte» → 20), unidades («kilos» → `Kilogram`) y las intenciones más frecuentes. No reemplaza al modelo — entiende menos variantes de frase — pero garantiza que **la demo nunca se cae por falta de internet o de cuota**.

El mismo intérprete corre además **dentro del navegador** (`frontend/src/interpreteLocal.js`) para el modo sin conexión, donde no hay backend con quien hablar.

POR QUÉ EL TURNO DEL AGENTE CORRE EN UN HILO APARTE

Llamar a Gemini puede tardar varios segundos. Hacerlo directo dentro de la ruta **async** bloqueaba **todo** el bucle de eventos: cualquier otra petición, de cualquier otra persona, a cualquier endpoint — hasta **/api/salud** — se quedaba esperando. Por eso **procesar_turno** se saca con **run_in_threadpool**.

El asistente contextual

Aparte del conteo, **POST /api/agente/asistente** responde preguntas sobre la pantalla en la que está la persona y sabe navegar: «lléveme al panel» cambia de vista. Las claves de destino tienen que calzar exactamente con las que usa **ir(destino)** en **App.jsx**; si no calzan, la navegación por voz apunta a una vista que no existe.

6 El modelo de datos

Dieciocho tablas, en `backend/modelos.py`.

TABLA	GUARDA
usuario	Las personas, su perfil y su estado. La clave no está aquí: la guarda Cognito.
asignacion_bodega	Qué bodegas puede contar cada auxiliar.
bodega	Las zonas y su estado: pendiente, en conteo, en auditoría o cerrada.
articulo	El catálogo oficial, con su código.
stock_sistema	Lo que el sistema cree que hay, contra lo que se compara el conteo.
alias_articulo	Cómo llama la gente a las cosas, contra el nombre oficial. Es lo que hace que «papa criolla» encuentre PAPA CRIOLLA PRECOCIDA .
sesion_conteo	Una toma de una bodega por una persona. Es el candado que evita conteos duplicados.
conteo	Cada renglón contado. Las correcciones no borran: apuntan al anterior con corrige_a .
alerta	Las diferencias que quedaron marcadas durante el conteo.
traza	Quién hizo qué y cuándo. Nunca se borra.
receta receta_ingredientes	Los platos con sus ingredientes y su rendimiento. Es la base del cálculo de pedidos.
linea_servicio	Lo pedido contra lo usado en un servicio. Es lo que compara la legalización.
aprobacion	Productos y bodegas creados en medio del conteo, esperando el visto bueno.
historial_cierre	El cierre de cada bodega, con su doble firma.
config_clave	Configuración del sistema por clave y valor: umbral de anomalía, modo sin conexión.
archivo_generado	Los reportes que se han sacado, para poder previsualizarlos y volver a descargarlos.
mensaje_soporte	La bandeja interna entre auxiliares y administrador.

Cómo se conectan

Tres cadenas explican casi todo el sistema:

CADENA	RECORRIDO
El conteo	bodega → sesion_conteo → conteo → alerta → historial_cierre . Una bodega se abre en una sesión, la sesión acumula renglones, los renglones que se salen del umbral generan alertas, y el cierre con doble firma congela el resultado.
El pedido	receta → receta_ingrediente → stock_sistema → linea_servicio . La receta dice cuánto se necesita por porción, el stock dice cuánto hay, y la diferencia es lo que hay que pedir. Al cerrar el turno, esa misma línea guarda lo que de verdad se usó.
El nombre	lo dictado → alias_articulo → articulo . Es la cadena que convierte «papa criolla» en un código oficial. Cuando no encuentra nada, nace una fila en aprobacion en vez de detener el conteo.

NADA SE BORRA

Corregir un conteo escribe una fila nueva que apunta a la anterior.
Desactivar a una persona pone **activo = 0**, no borra la fila. Rechazar una aprobación la deja marcada como rechazada. Un inventario que pierde su historia no sirve para auditar.

7 La API

Noventa endpoints en **backend/main.py**, agrupados por familia.

FAMILIA	CUÁNTOS	PARA QUÉ
/api/usuarios	16	El perfil propio, la administración de cuentas y la asignación de bodegas.
/api/bodegas	15	Listar, abrir, cerrar, detalle y exportaciones.
/api/reportes	6	Generar, previsualizar y descargar.
/api/pedidos	6	Calcular desde la receta, enviar y aprobar.
/api/soporte	5	Reportar un problema, escribirle al administrador y la bandeja.
/api/recetas	5	Mantener los platos y sus ingredientes.
/api/articulos	4	Buscar en el catálogo y consultar existencias.
/api/legalizacion	3	Comparar, ajustar y confirmar el cierre del servicio.
/api/aprobaciones · /api/alertas · /api/trazabilidad	9	El control del administrador.
/api/agente · /api/voz	4	El turno de conversación, el asistente contextual y las voces.
/api/panel · /api/analisis · /api/ajustes	6	Indicadores, análisis de consumo y configuración.
/api/salud	1	Estado del sistema. Es el que consulta la pantalla de Ayuda.

Todos exigen un access token válido salvo **/api/salud** y **/api/registro-completado**. Los que solo puede usar el administrador llevan **Depends(requiere_perfil("auditor"))**.

LOS ERRORES LLEGAN CON SUS CABECERAS CORS

Un error que sale sin las cabeceras de CORS llega al navegador como «error de red», y la pantalla dice «Sin conexión con el servidor. Revise el Wi-Fi» — mandando a buscar el problema en el router mientras el servidor respondía perfecto. Por eso los manejadores de excepción las ponen a mano: para que el error se vea tal cual es.

8 El frontend

Catorce vistas, una barra lateral y un puñado de módulos compartidos.

Cómo está organizado

ARCHIVO	DE QUÉ RESPONDE
App.jsx	El menú (MENU), qué vista está activa, la sesión y el contexto que se pasa a las vistas.
vistas/	Las 14 pantallas, una por archivo.
api.js	Todas las llamadas al backend, y esFalloRed , que distingue un fallo de red de un error del servidor.
cognito.js	Registro, ingreso, clave y verificación en dos pasos.
voz.js	Escuchar y hablar.
interpreteLocal.js	El intérprete del modo sin conexión.
colaOffline.js	La cola de conteos pendientes de sincronizar.
accesibilidad.js	Alto contraste y tamaño de letra.
tutorial.js · VideoRecorrido.jsx	El recorrido en video que se abre al ingresar.

El menú es la única fuente de verdad de la navegación

La lista **MENU** de **App.jsx** define el orden, el título, la vista y si la opción es solo del administrador (**soloAuditor: true**). Agregar una pantalla es agregar una entrada ahí y su componente en **vistas/**.

QUIEN DESPLAZA ES .CONTENIDO, NO LA VENTANA

El contenedor raíz ocupa **100dvh** y el que tiene la barra de desplazamiento es **.contenido**. Un **window.scrollTo** no mueve nada. Vale la pena saberlo antes de perder una tarde.

9 Trabajar sin conexión

Lo que pasa cuando se cae el internet en plena bodega.

El conteo no se detiene. El navegador dispara el evento `offline`, la pantalla de Conteo cambia sola a un formulario de respaldo, y lo que se registre se guarda en `localStorage` bajo la clave de la **sesión de conteo activa**. Un aviso muestra cuántos registros quedan pendientes, tanto en la pantalla como en la barra lateral.

Al volver la señal, el evento `online` dispara la sincronización: cada renglón se reenvía y se confirma, y **solo se saca de la cola lo que de verdad se confirmó**. Si uno falla, o vuelve a caerse la red a mitad, el resto queda guardado para el próximo intento — antes, cualquier falla borraba toda la cola sin distinguir qué alcanzó a guardarse.

LA COLA VA POR SESIÓN DE CONTEO, NO POR USUARIO

La clave es `cv_offline_<sesionId>`. Sin una bodega abierta no hay sesión, y por lo tanto no hay dónde encolar: el modo sin conexión solo tiene sentido dentro de un conteo en curso.

10 Reportes y archivos

Seis salidas, repartidas en las pantallas a las que pertenecen.

ARCHIVO	SE GENERA DESDE
Consolidado para My Inventory	Reportes › Consolidado de la toma
Diferencias por bodega	Reportes › Consolidado de la toma
Análisis de consumo	Reportes › Análisis de consumo
Estado del tablero	Bodegas
Detalle de una bodega	Bodegas › detalle
Registro de trazabilidad	Ajustes › Registro de trazabilidad

Todo lo generado queda en **archivo_generado**, así que se puede **previsualizar en pantalla antes de descargar** y volver a bajar después. Los archivos salen en XLSX con **openpyxl**, con los códigos oficiales del catálogo — que es lo que My Inventory espera recibir.

11 Trazabilidad y auditoría

Cómo se responde a «¿quién cambió esto?».

Cada acción con consecuencia llama a **registrar**(usuario, accion, detalle, nivel), que escribe en **traza**. Ahí quedan los conteos, las correcciones, las aprobaciones, los cierres, los reportes de soporte y los mensajes. El administrador lo consulta y lo exporta desde **Ajustes › Registro de trazabilidad**.

Las cuatro pestañas de Auditoría

PESTAÑA	QUÉ RESUELVE
Recuento ciego y cierre	Volver a contar una bodega sin ver los números del auxiliar. La comparación solo se revela al terminar, y el cierre lleva doble firma.
Aprobaciones	Los productos y bodegas que alguien creó en medio del conteo para no detenerse. Al aprobarlos entran al catálogo con su código definitivo.
Pedidos pendientes	Autorizar lo solicitado antes de que salga del almacén.
Bandeja de alertas	Las diferencias marcadas durante el conteo, agrupadas por tipo.

POR QUÉ EL RECUESTO ES CIEGO

Si quien audita ve el número del primer conteo, lo confirma. El sesgo de anclaje convierte la auditoría en un trámite. Ocultar el dato hasta el final es lo que hace que la segunda pasada valga algo.

12 Pruebas

Qué hay, cómo se corre y qué cubre.

SUITE	CÓMO SE CORRE	QUÉ CUBRE
Backend 128 pruebas	<code>cd backend</code> <code>python -m pytest tests/ -q</code>	El agente y sus conversaciones, el intérprete, la conciliación, las recetas, la seguridad y las regresiones de legalización.
Frontend 5 archivos	<code>cd frontend</code> <code>npm test</code>	Lógica pura: intérprete local, cola sin conexión, accesibilidad, confirmación por voz y tutorial.

Las pruebas de backend usan **conftest.py** con una base en memoria, así que no tocan **cuentavoz.db**. Las de frontend usan **node:test**, sin infraestructura de renderizado: se prueba la lógica que no depende del DOM.

LAS PRUEBAS CON NOMBRE REGRESIONES NO SON OPCIONALES

`test_regresiones_seguridad.py` y `test_regresiones_legalizacion.py` existen porque esos fallos ya ocurrieron una vez. Si una de ellas se pone en rojo, no es una prueba frágil: es el mismo error volviendo.

13 Despliegue

Cómo llega esto a producción.

El despliegue está descrito en **render.yaml** y detallado en **DESPLIEGUE.md**.

Son tres servicios en Render:

SERVICIO	TIPO	QUÉ ES
cuentavoz-db	PostgreSQL	La base de producción.
cuentavoz-api	Web (Python)	El backend con Uvicorn.
cuentavoz	Estático	El build del frontend, con reescritura para que las rutas de la aplicación funcionen.

La misma base de código sirve en local y en producción: lo único que cambia es **DB_URL** y las llaves. Las credenciales se cargan como variables de entorno del servicio, nunca en el repositorio.

EL SERVIDOR SE DUERME

En el plan gratuito de Render el backend entra en reposo tras un rato sin tráfico, y la primera petición puede tardar hasta un minuto. Por eso las pantallas que dependen de la red avisan «el servidor estaba en reposo y está despertando» en vez de dar un error seco.

14 Decisiones de diseño

Por qué las cosas son como son. Útil antes de cambiarlas.

DECISIÓN	POR QUÉ
Confirmar siempre antes de guardar	El reconocimiento de voz se equivoca. Un inventario con datos que nadie aprobó es peor que no tener inventario.
Nunca sobrescribir	Sin el valor anterior no hay auditoría posible.
Intérprete local además de Gemini	Una bodega con mala señal, o una cuota agotada, no pueden dejar a nadie sin poder contar.
La clave la guarda Cognito	Lo que no se almacena no se puede filtrar.
Permisos también en el endpoint	Ocultar una opción del menú no es seguridad.
El auxiliar no ve pantallas que no puede usar	Mostrarle Ajustes en solo lectura le enseña controles que no puede tocar y hace ver la herramienta más complicada de lo que es para él.
Los reportes se previsualizan	Descargar el archivo equivocado y cargarlo a My Inventory cuesta más que un clic de más.
Un mensaje se responde una sola vez	Dos respuestas al mismo mensaje pisaban la anterior en silencio, y quien ya la había leído no se enteraba del cambio.

15 Cuando algo falla

Los tropiezos más frecuentes, y qué revisar primero.

SÍNTOMA	CAUSA PROBABLE	QUÉ HACER
«Sesión inválida o vencida» al entrar	Quedó un token viejo en <code>localStorage</code> .	Limpiar el almacenamiento del sitio y volver a entrar.
El navegador dice «error de red» pero el servidor responde	El origen no está en la lista de CORS.	Agregarlo a <code>ORIGEN_PERMITIDO</code> y reiniciar el backend.
El agente entiende menos de lo esperado	No hay <code>GOOGLE_API_KEY</code> : está corriendo el intérprete local.	Ponerla en el <code>.env</code> . Lo confirma Ayuda › Estado del sistema .
Un auxiliar no ve su bodega	No se la asignaron.	Ajustes › Gestión de usuarios › asignar bodegas.
La primera petición tarda un minuto	El servidor estaba en reposo.	Esperar. La aplicación ya lo avisa en pantalla.
El correo al administrador no sale	No hay <code>BREVO_API_KEY</code> .	Es esperado: el mensaje igual queda en la bandeja y en la trazabilidad.
Una prueba de regresiones se pone en rojo	Volvió un fallo que ya se había corregido.	No ajustar la prueba. Arreglar el código.

CuentaVoz · Tu voz cuenta

Guía técnica, versión 5.0 — agosto de 2026.
Elaborada por el equipo StockXperts para la
operación de bodegas de Colsubsidio.

El código manda

Esta guía explica el porqué y el cómo, no reemplaza al repositorio. Cuando una y otro no coincidan, el código tiene la razón — y esta guía tiene un error que vale la pena corregir.